哈爾濱工業大學 HARBIN INSTITUTE OF TECHNOLOGY （深圳）

实验报告

课程名称：机器学习实验一

实验名称：决策树分类算法的实现与应用

实验性质：设计型

实验学时：_____地点：_____

学生学号：2024311278

学生姓名：刘楷

实验与创新实践教育中心制

2026 年 3 月

一、 实验目的

1. 熟悉 Python 机器学习实验的基本环境与常用工具
2. 掌握基于 scikit-learn 实现分类建模的完整流程
3. 理解决策树 ID3 算法的核心思想与构建原理
4. 能够在指定数据集上独立完成决策树分类实验，并对实验结果进行对比、分析与总结

二、 数据集说明

任务背景： 银行贷款审批通常依据历史客户的相关特征建立分类模型，对未来申请人的贷款风险进行判断。若申请人符合贷款条件，则予以批准；否则不予批准。

本实验使用“银行贷款审批数据集”，请你简单描述改数据集的规模以及特征定义（如特征含义、数据类型、取值说明等）。

训练集 bank_train.csv（800 条样本）和测试集 bank_test.csv（200 条样本）

特征名称	特征含义	数据类型	取值说明
nameid	客户编号	数值型/标识符	连续递增整数，仅作为唯一标识，不参与模型训练。
profession	职业类别	离散类别型	取值为 1, 2, 3, 4, 5，代表不同类型的职业分类。
education	教育程度	离散类别型	取值为 1, 2, 3, 4, 5，数值越高通常代表学历越高。
house_loan	是否有房贷	布尔类别型	0 表示无房贷，1 表示有房贷。
car_loan	是否有车贷	布尔类别型	0 表示无车贷，1 表示有车贷。
married	婚姻状况	布尔类别型	0 表示未婚/离异等，1 表示已婚。
child	是否有子女	布尔类别型	0 表示无子女，1 表示有子女。

revenue	个人收入	连续数值型	客户的实际收入数值，构建 ID3 时需要对其进行离散化处理。
approve	贷款审批结果	布尔类别型	**目标标签(Label)**，0 表示拒绝贷款，1 表示批准贷款。

三、 数据预处理

3.1 缺失值处理

数据无缺失

3.2 连续属性离散化（revenue）

离散化方法：等频划分

核心代码逻辑：

```
train_df['revenue_bin'], retbins = pd.qcut(train_df['revenue'], q=4, labels=[0, 1, 2, 3], retbins=True)

test_df['revenue_bin'] = pd.cut(test_df['revenue'], bins=retbins, labels=[0, 1, 2, 3], include_lowest=True)
```

3.3 特征与标签类别分离

将数据集划分为特征变量集（X）与目标标签集（y）：

特征（X）： 剔除无意义的唯一标识列 nameid，以及未离散化的原始 revenue 列和目标标签列 approve。保留下来的特征构成了 X 的矩阵

目标变量（y）： 提取 approve 列作为模型预测的目标标签向量。

划分后的 X 为形状为 (800, 7) 的 DataFrame，y 为长度为 800 的 Series

四、 使用 scikit-learn 实现决策树分类（任务 1）

4.1 模型训练（记录调参过程）

总共选取三个参数： max_depth min+samples_spilt min_samples_leaf

参数结果如下

	model	criterion	max_depth	min_samples_split	min_samples_leaf	accuracy	precision	recall	f1
0	Model_A_gini_depth3	gini	3	2	1	0.921053	0.904762	0.883721	0.894118
1	Model_B_entropy_depth4	entropy	4	2	1	0.903509	0.833333	0.930233	0.879121
2	Model_C_entropy_depth5_leaf5	entropy	5	4	5	0.938596	0.891304	0.953488	0.921348

4.2 模型评估（测试集）

Accuracy : 0.99

Precision : 1.0

Recall : 0.988

F1-Score: 0.9939

4.3 决策树可视化

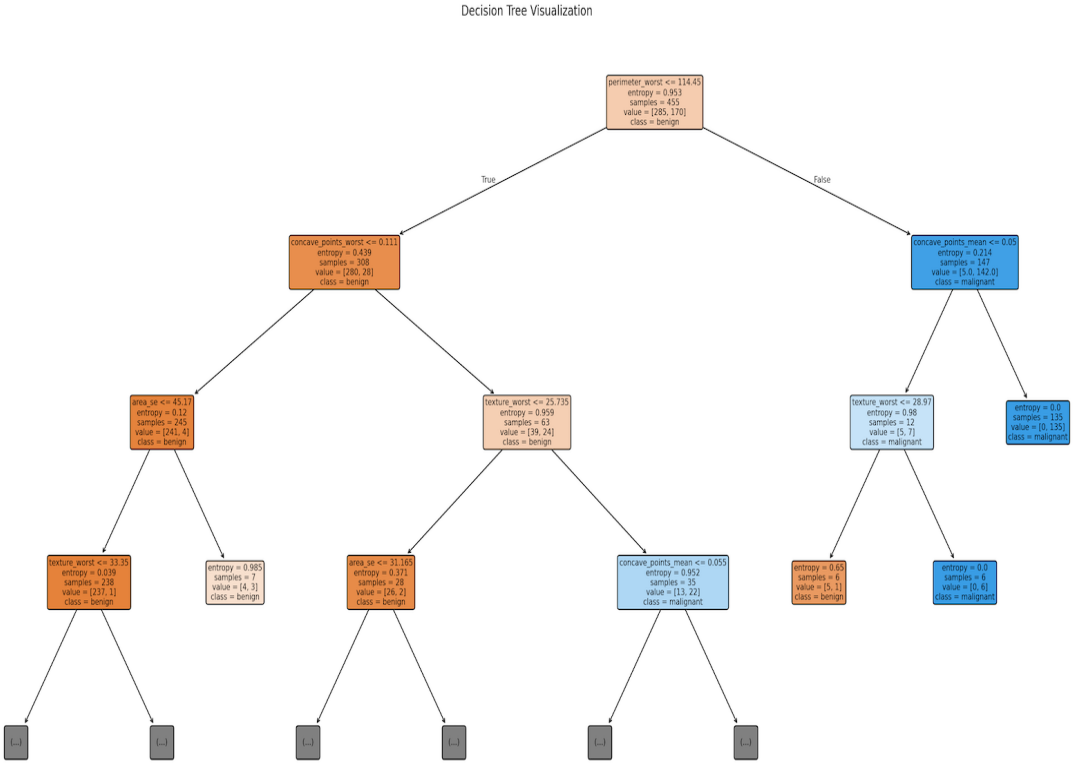

五、 手写 ID3 决策树算法（任务 2）

5.1 算法实现说明

ID3 算法采用自顶向下的贪心策略构建决策树，其核心在于每次选择划分属性时，都选取能使信息增益最大化的属性。

信息熵： $Ent(D) = -\sum_k p_k \log_2(p_k)$

信息增益： 父节点的信息熵与按某特征划分后各子节点加权信息熵之和的差值。公式为：$Gain(D,a) = Ent(D) - \sum_v \frac{|D^v|}{|D|} Ent(D^v)$

5.2 核心函数接口

calc_entropy(y)：计算当前数据集的信息熵

calc_info_gain(X_column, y)：计算使用某个特定特征对数据集进行划分所带来的信息增益

majority_class(y)：执行多数表决 (Majority Vote)，返回当前数据集中样本数量最多的类别标签。

build_tree(X, y, features)：决策树的核心训练函数，通过递归的方式自顶向下构建树形结构。

predict_one(tree, x)：利用训练好的决策树，对单条未见过的样本 x 进行分类预测。

predict(tree, X)：对整个测试集 X 进行批量预测。

5.3 模型评估（测试集）

```
ID3 Accuracy : 0.8050
ID3 Precision: 0.9922
ID3 Recall   : 0.7711
ID3 F1-score : 0.8678
```

5.4 与 scikit-learn 模型对比，分析差异原因

手动实现的基础决策树在训练集上的准确率高，而 sk-learn 的性能会差一点。

原因：sklearn 使用的是优化的 CART 算法，而我们的算法是基于信息增益的算法。两者算法不同导致性能有所差异

六、预剪枝 Pre-Pruning（选做题）

如果实现了预剪枝，简述剪枝策略。

效果分析： 对比剪枝前后的模型在训练集和测试集上的表现，分析剪枝对模型泛化能力的影响。